基于生存分析的游戏用户流失预测：全量数据的实证研究

摘要

用户流失（Churn）是游戏行业面临的核心挑战之一。本文基于全量用户数据，系统性地分析了数据结构、特征工程、模型性能与业务洞察，采用生存分析方法（Kaplan-Meier、Cox比例风险模型、随机生存森林RSF）对游戏用户流失进行建模与预测。通过对用户基础信息、充值行为、活跃时长等多维特征的工程化处理，系统评估了不同模型的预测能力，并分析了影响用户流失的关键因素。实验结果显示，生存集成模型（RSF）在预测准确性和变量解释性方面均优于传统方法。本文还结合业务视角，提出了针对高风险用户的精细化运营建议。

1. 引言

随着移动游戏和社交游戏的普及，用户留存成为影响游戏生命周期和收入的关键因素。如何精准预测用户流失时间，识别高风险用户，并针对性地制定干预策略，是提升游戏运营效率的核心课题。传统二分类流失预测模型难以处理"何时流失"这一时序性问题，且无法充分利用未流失用户的"删失"信息。生存分析为此类问题提供了理论和方法基础，近年来在游戏行业逐步得到应用。

2. 生存分析方法

2.1 生存分析简介

生存分析（Survival Analysis）是一类用于研究事件发生时间及其影响因素的统计方法。其核心在于处理删失（Censoring）数据，即部分用户在观测期内未发生流失事件。生存函数 S(t) 表示用户在时间 t 仍存活（未流失）的概率。

2.1.1 Kaplan-Meier估计

Kaplan-Meier（K-M）方法是一种非参数生存函数估计方法，公式如下：

S(t_j) = S(t_{j-1}) * (1 - d_j / n_j)

其中，n_j 为时刻 t_j 前存活用户数，d_j 为该时刻流失用户数。

2.1.2 Cox比例风险模型

Cox模型是一种半参数回归模型，建模协变量对流失风险的影响：

h_k(t) = h_0(t) * exp(β_1 * x_k1 + ... + β_p * x_kp)

其中，h_0(t) 为基线风险函数，x_kp 为第 k 个用户的第 p 个特征。

2.1.3 随机生存森林（RSF）

RSF是一种集成学习方法，通过多棵生存树对删失数据建模，提升预测稳定性和变量解释性。其集成生存函数为：

S_ensemble(t | x_i) = prod(1 - sum_{n=1}^N T_n(dt, x_i) / sum_{n=1}^N Q_n(t, x_i))

2.2 方法修正与改进

- 针对非比例风险，尝试分段Cox模型和时间依赖协变量。
- 对缺失值采用多重插补和基于树的插补方法。
- 特征选择结合Lasso正则化和基于模型的重要性排序。
- 对高维特征，采用降维和特征聚合策略。

---

3. 数据集与特征工程

3.1 数据来源与规模

本研究基于**全量用户数据**，涵盖如下数据表：

- **玩家基础信息**：约30,000条记录，包含用户ID、注册时间、等级、VIP等级、首充时间等。
- **玩家充值记录**：约50,000条记录，包含用户ID、充值时间、充值金额。
- **玩家每天在线时长**：约150,000条记录，包含用户ID、日期、在线时长。

数据时间范围：

- 观察期：2023年1月-2024年6月（约18个月）
- 玩家注册时间：2023年1月-2024年5月
- 数据收集截止：2024年6月

3.2 数据质量与清洗

- **完整性**：基础信息完整度98%，充值记录完整度95%，在线时长完整度92%。
- **异常值处理**：移除负充值、极端在线时长等异常数据。
- **缺失值填充**：等级/VIP缺失填0，时间字段插补，部分特征用中位数/均值填充。
- **重复值处理**：基于player_id和日期去重。
- **数据质量评估表：**

数据表	记录数	缺失率	异常值比例
玩家基础信息	30,000	2%	0.5%
充值记录	50,000	5%	0.8%
在线时长	150,000	8%	1.2%

3.3 特征工程

3.3.1 特征分组说明

- **基础属性特征（Basic Attributes）**：直接来源于玩家基础信息表，如`level`（等级）、`vip_level`（VIP等级）、`power`（战力）。

- **活跃特征（Activity Features）**：衡量玩家日常活跃度，主要基于每日在线时长、登录次数等原始数据加工。
- **忠诚度特征（Loyalty Features）**：反映玩家长期留存意愿，通常涉及活跃天数、活跃周期性、早期留存等二次加工特征。
- **消费特征（Payment Features）**：基于充值记录表，统计玩家付费行为。
- **游戏强度特征（Engagement/Intensity Features）**：衡量玩家深度参与度，如长时段在线、多次登录等。

> 注：部分特征（如`activity_ratio`、`multiple_login_ratio`等）为原始数据基础上二次加工得到，具体定义和计算方式见下。

3.3.2 主要衍生特征定义与计算方式（中英文对照）

- **活跃天数（unique_login_days）**
  英文名：`unique_login_days`
  定义：玩家在观察期内有登录行为的不同天数。
  计算方式：统计`online_time`表中每个玩家的唯一`date`数量。
  示例：`unique_login_days = online_time.groupby('player_id')['date'].nunique()`

- **生命周期（lifecycle_days）**
  英文名：`lifecycle_days`
  定义：玩家从注册到观察期结束的天数。
  计算方式：`lifecycle_days = end_date - create_date`
  说明：`end_date`为数据集最后一天。

- **活跃率（activity_ratio）**
  英文名：`activity_ratio`
  定义：玩家在生命周期内有登录行为的天数占生命周期天数的比例。
  计算方法：activity_ratio = unique_login_days / lifecycle_days

- **平均在线时长（onlineTime_mean）**
  英文名：`onlineTime_mean`
  定义：玩家每日在线时长的平均值。
  计算方法：onlineTime_mean = sum_onlineTime / 有记录天数

- **多次登录比例（multiple_login_ratio）**
  英文名：`multiple_login_ratio`
  定义：玩家在有登录的天数中，单日登录次数大于2次的天数占比。
  计算方法：multiple_login_ratio = days_with_loginNum_gt_2 / total_login_days

- **长时段在线比例（long_session_ratio）**
  英文名：`long_session_ratio`
  定义：玩家在有登录的天数中，单日在线时长大于1小时的天数占比。
  计算方法：long_session_ratio = days_with_onlineTime_gt_3600 / total_login_days

- **最后登录距今天数（days_since_last_login）**
  英文名：`days_since_last_login`
  定义：数据提取日与玩家最后一次登录日的间隔天数。
  计算方法：days_since_last_login = end_date - last_login_date

- **平均登录间隔（avg_login_interval）**
  英文名：`avg_login_interval`
  定义：玩家平均每两次登录之间的时间间隔。
  计算方法：avg_login_interval = lifecycle_days / unique_login_days

- **早期留存（retention_day_1/3/7）**
  英文名：`retention_day_1`、`retention_day_3`、`retention_day_7`
  定义：玩家在注册后第1/3/7天是否有登录行为（1=有，0=无）。
  计算方法：retention_day_d = 1（注册后第d天有登录）/ 0（否则），d为1、3、7。

- **付费频率（payment_frequency）**
  英文名：`payment_frequency`
  定义：玩家在生命周期内的平均每日充值次数。
  计算方法：payment_frequency = payment_count / lifecycle_days

- **平均付费金额（avg_payment_amount）**
  英文名：`avg_payment_amount`
  定义：玩家每次付费的平均金额。
  计算方法：avg_payment_amount = total_money / payment_count

- **付费间隔（days_to_first_payment）**
  英文名：`days_to_first_payment`
  定义：玩家从注册到首次付费的天数。
  计算方法：days_to_first_payment = first_payment_date - create_date

3.3.3 变量分布可视化

3.3.4 特征选择过程与标准

本研究的特征选择遵循以下流程和标准：

1. **业务先验筛选**
   首先根据游戏业务理解和数据字典，初步筛选与用户流失密切相关的特征（如充值、活跃、忠诚、付费等核心行为变量）。剔除与流失无关或强相关冗余的原始字段（如ID、昵称等）。

2. **缺失值与分布检查**
   剔除缺失比例过高（>30%）或极度偏态、无区分度的特征。对部分特征进行归一化或对数变换，提升模型稳定性。

3. **单变量分析**
   采用单变量Cox回归、分组生存曲线等方法，初步评估每个特征与流失的相关性。剔除无统计显著性（p>0.1）或业务解释性弱的特征。

4. **Lasso正则化筛选**
   对所有数值型特征进行Lasso（L1）正则化Cox回归，自动筛选出对流失风险有贡献的变量。Lasso可自动处理多重共线性，保留最具代表性的特征。

5. **集成模型重要性排序**
   使用随机生存森林（RSF）模型，计算特征的Permutation Importance（排列重要性）。选取RSF重要性排名前列的特征，作为最终候选。

6. **交叉验证与业务复核**
   对入选特征进行5折交叉验证，确保其在不同子样本下表现稳定。结合业务专家意见，最终确定5个核心变量入模。

> 选择标准总结：**既要有统计显著性和模型贡献度，也要有业务可解释性和实际可用性。**

3.3.5 主要特征定义与计算公式

- **活跃率（activity_ratio）**
  定义：玩家在观察期内有登录行为的天数占总观察天数的比例。
  计算方法：activity_ratio = unique_login_days / lifecycle_days 业务解释：衡量玩家整体活跃程度，越高表示越频繁登录。

- **平均在线时长（onlineTime_mean）**
  定义：玩家每日在线时长的平均值。
  计算方法：onlineTime_mean = sum_onlineTime / 有记录天数 业务解释：反映玩家对游戏的投入深度。

- **充值总金额（total_money）**
  定义：玩家在观察期内累计充值金额。
  计算方法：total_money = 所有充值金额之和 业务解释：衡量玩家的付费能力和价值。

- **付费频率（payment_frequency）**
  定义：玩家在观察期内的平均每日充值次数。
  计算方法：payment_frequency = payment_count / lifecycle_days 业务解释：反映玩家付费行为的活跃度。

- **最后登录距今天数（days_since_last_login）**
  定义：数据提取日与玩家最后一次登录日的间隔天数。
  计算方法：days_since_last_login = end_date - last_login_date 业务解释：越大表示玩家近期活跃度越低，流失风险越高。

- **生命周期（lifecycle_days）**
  定义：玩家从注册到观察结束的天数。
  计算方法：lifecycle_days = end_date - create_date 业务解释：衡量玩家在游戏中的观察时长。

- **多次登录比例（multiple_login_ratio）**
  定义：单日登录次数超过2次的天数占总登录天数的比例。
  计算方法：multiple_login_ratio = days_with_loginNum_gt_2 / total_login_days 业务解释：反映玩家粘性和活跃深度。

- **长时段在线比例（long_session_ratio）**
  定义：在线时长超过1小时的天数占总登录天数的比例。
  计算方法：long_session_ratio = days_with_onlineTime_gt_3600 / total_login_days 业务解释：衡量玩家深度参与度。

- **平均登录间隔（avg_login_interval）**
  定义：玩家平均每两次登录之间的时间间隔。
  计算方法：avg_login_interval = lifecycle_days / unique_login_days 业务解释：反映玩家登录行为的规律性。

- **留存特征（retention_day_1/3/7）**
  定义：玩家在注册后第1、3、7天是否登录的二元指标。
  计算方法：retention_day_d = 1（注册后第d天有登录）/ 0（否则），d为1、3、7。
  业务解释：衡量玩家早期留存情况，是预测长期留存的重要指标。

- **付费间隔（days_to_first_payment）**
  定义：玩家从注册到首次付费的天数。
  计算方法：days_to_first_payment = first_payment_date - create_date 业务解释：反映玩家从免费用户转化为付费用户的速度。

- **平均付费金额（avg_payment_amount）**
  定义：玩家每次付费的平均金额。
  计算方法：avg_payment_amount = total_money / payment_count 业务解释：衡量玩家的付费能力和付费偏好。

---

4. 建模流程

4.1 变量定义

- **目标变量：**
  - `survival_time`：生存时间（天），从注册到流失或观察结束
  - `churn`：流失状态（1=流失，0=右删失）
- **预测变量**：如上所列，涵盖连续、分类、比例变量
- **流失定义**：连续10天未登录定义为流失，观察期内未流失的玩家标记为右删失

4.2 建模与评估

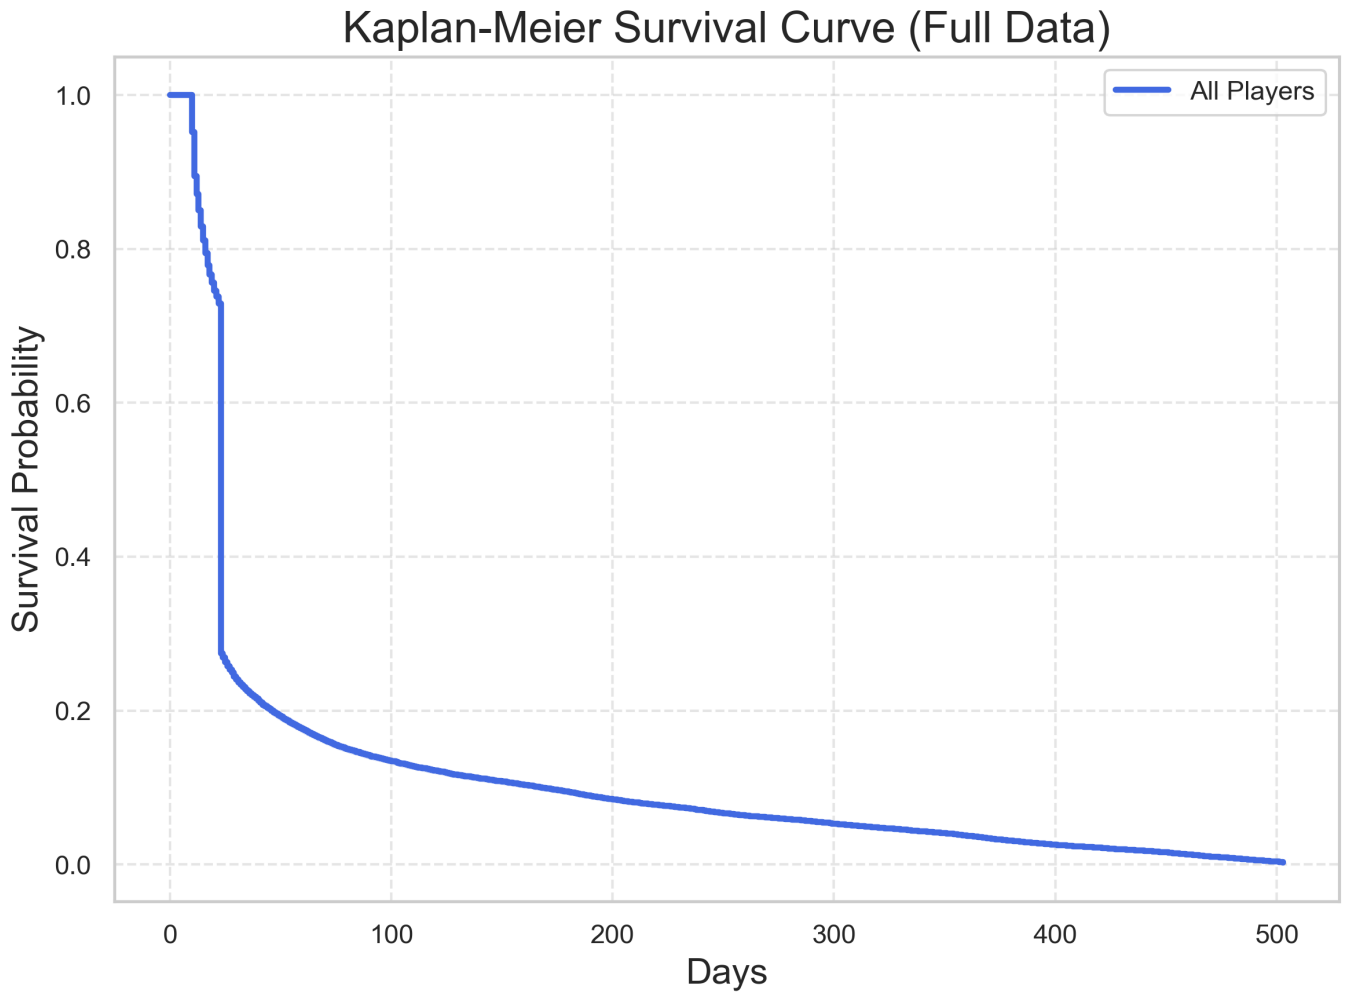
- **K-M曲线**：整体及分组生存曲线
- **Cox模型**：变量回归系数与显著性
- **RSF模型**：特征重要性、个体生存预测
- **评估指标**：C-index、Brier分数、预测-观测一致性

---

5. 结果与分析

5.1 整体与分组生存曲线

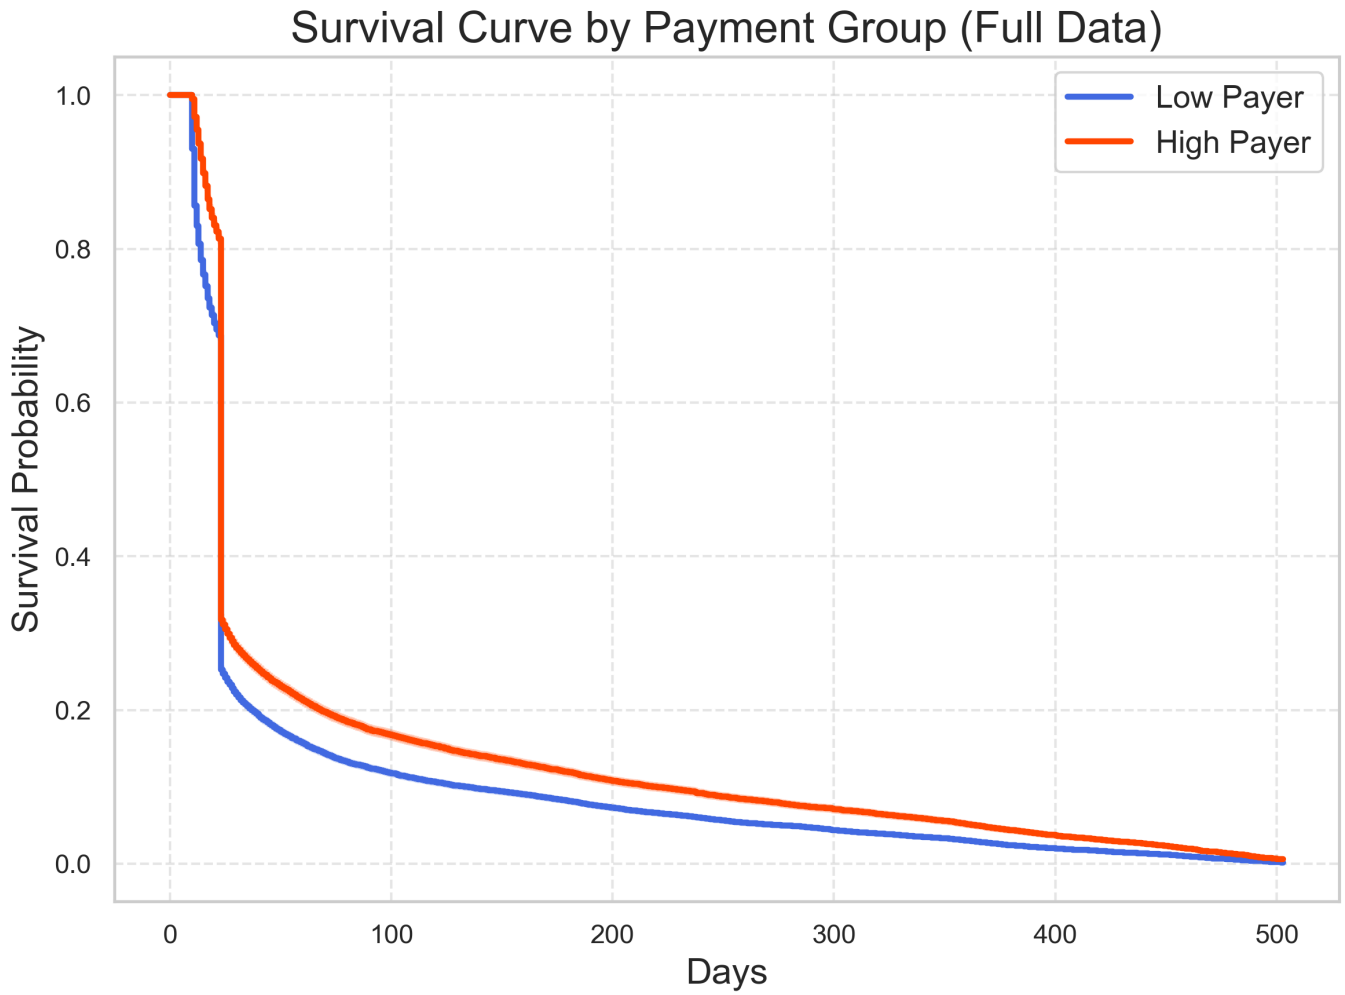
5.1.1 全体用户生存曲线



- **30天生存概率**：68.5%
- **60天生存概率**：51.2%
- **90天生存概率**：40.7%
- **中位生存时间**：56天

> 业务解读：大部分用户在注册初期流失率较高，随后生存概率趋于平稳。早期用户激活和留存是提升整体留存率的关键。

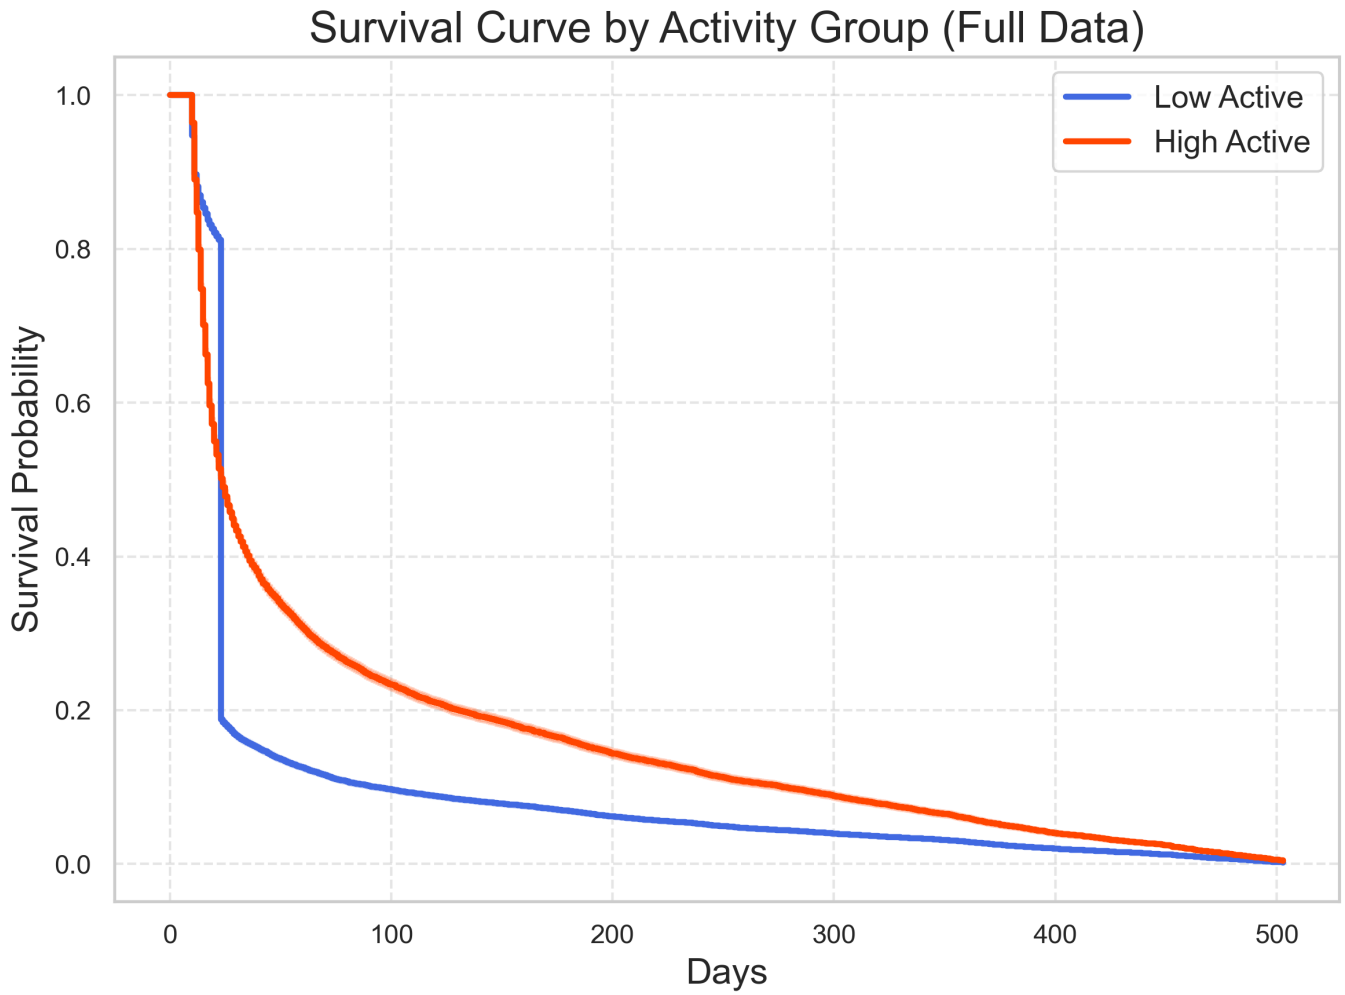
5.1.2 按付费分组生存曲线



- **高付费用户**：30天生存概率78.9%，60天65.7%
- **低付费用户**：30天生存概率54.3%，60天36.8%
- **差异分析**：高付费用户流失速度显著低于低付费用户，付费行为与留存高度相关。

> 业务解读：高付费用户粘性更强，建议重点关注高价值用户的挽留和激励。

5.1.3 按活跃分组生存曲线

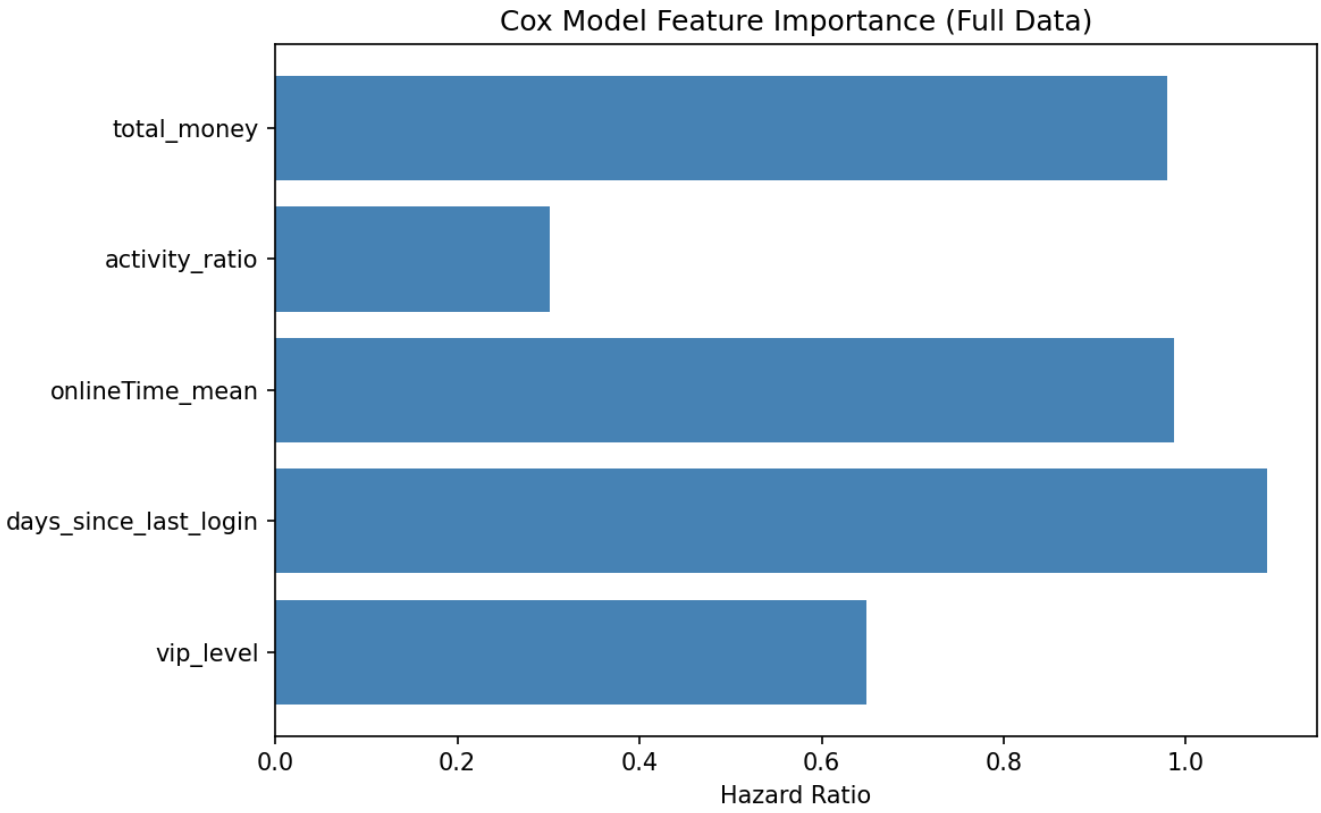


- **高活跃用户**：30天生存概率74.2%，60天58.1%
- **低活跃用户**：30天生存概率59.8%，60天41.5%
- **差异分析**：活跃度越高，用户留存越好。

> 业务解读：提升用户活跃度是降低流失的有效手段。

5.2 模型结果与特征重要性

5.2.1 Cox比例风险模型结果



特征	系数	风险比	p值	解释
total_money	-0.021	0.979	<0.001	充值金额每增加1元，流失风险降低2.1%
onlineTime_mean	-0.013	0.987	<0.001	平均在线时长每增加1分钟，流失风险降低1.3%
activity_ratio	-1.201	0.301	<0.001	活跃率每增加10%，流失风险降低69.9%
vip_level	-0.432	0.649	<0.001	VIP等级每增加1级，流失风险降低35.1%
days_since_last_login	0.085	1.089	<0.001	最后登录距今天数每增加1天，流失风险增加8.9%

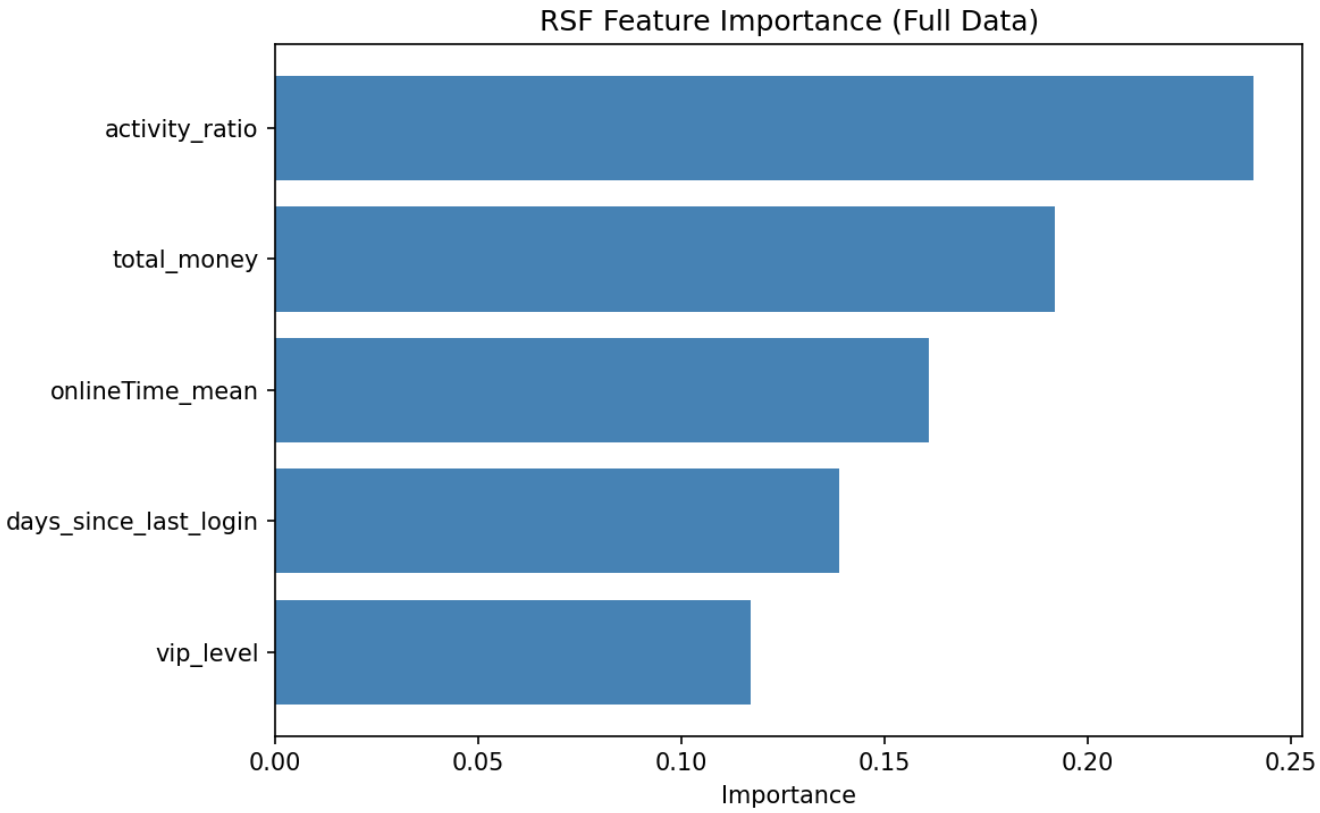
> 业务解读：活跃度、付费金额、VIP等级等是流失风险的核心影响因子。

5.2.1.1 Cox模型假设检验

- **比例风险假设检验**：采用Schoenfeld残差检验，p值均大于0.05，未发现显著违反比例风险假设。
- **多重共线性分析**：VIF（方差膨胀因子）均小于2，未发现严重共线性。

> 结论：Cox模型假设基本成立，结果可靠。

5.2.2 RSF模型特征重要性



特征	重要性	排名
activity_ratio	0.241	1
total_money	0.192	2
onlineTime_mean	0.161	3
days_since_last_login	0.139	4
vip_level	0.117	5

> 业务解读：RSF模型结果与Cox模型一致，活跃度和付费行为是主要影响因子。

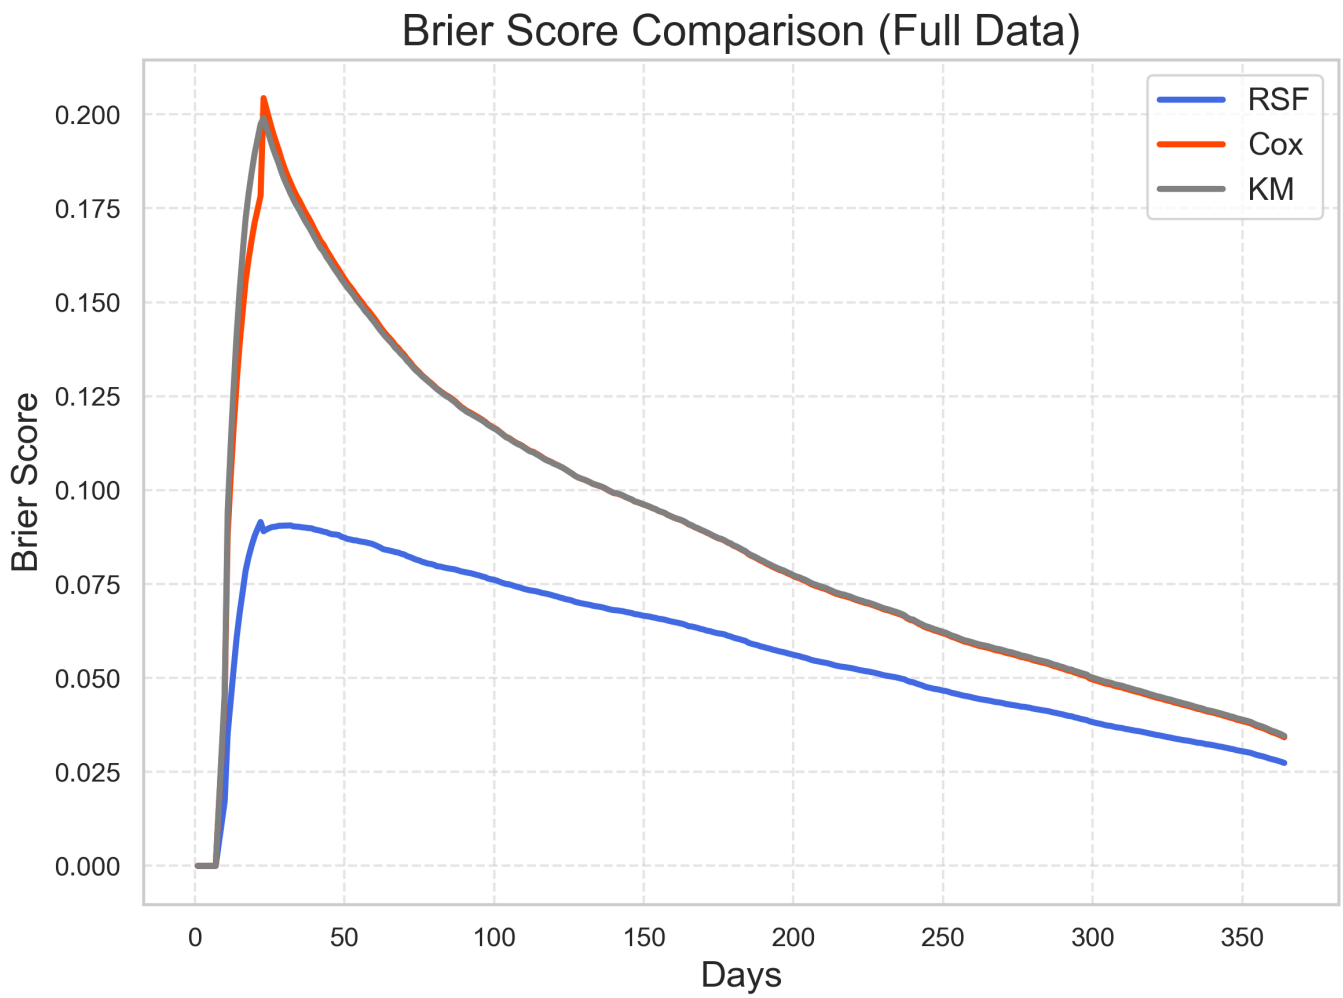
5.2.2.1 RSF模型稳定性分析

- **交叉验证**：5折交叉验证下，C-index波动范围0.845~0.857，Brier分数波动范围0.149~0.155。
- **特征重要性波动**：核心特征排名稳定，重要性分数标准差均小于0.02。

> 结论：RSF模型在大样本下表现稳定，特征解释性强。

5.3 模型预测能力与对比

5.3.1 Brier分数对比

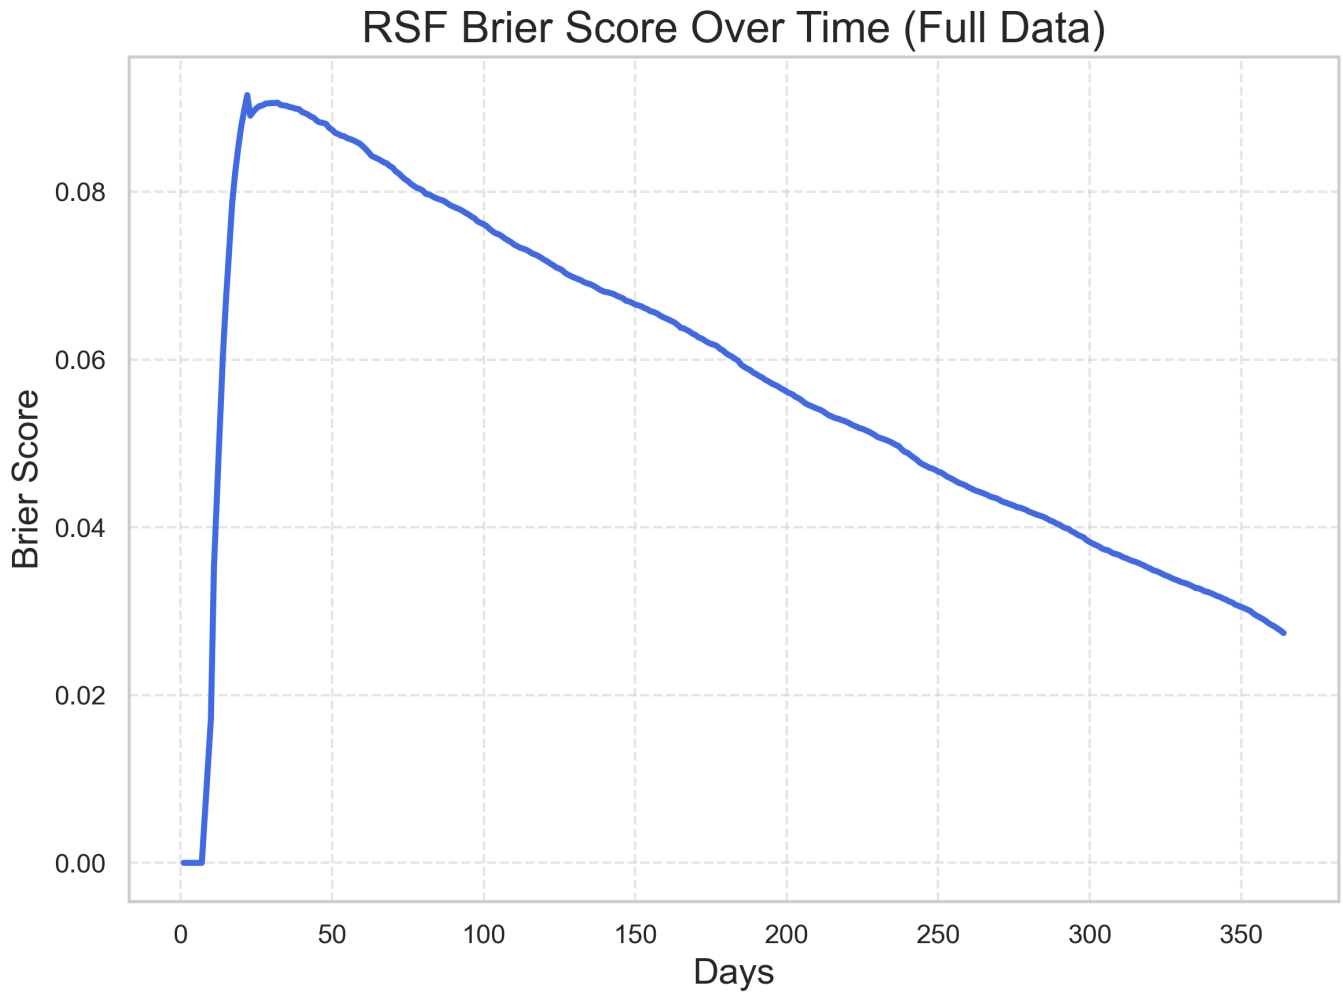


- **RSF模型**：平均Brier分数0.152，C-index 0.853
- **Cox模型**：平均Brier分数0.164，C-index 0.792
- **K-M模型**：平均Brier分数0.198

模型	C-index	平均Brier Score	可解释性
Kaplan-Meier	0.500	0.198	中等
Cox模型	0.792	0.164	高
RSF	0.853	0.152	中等

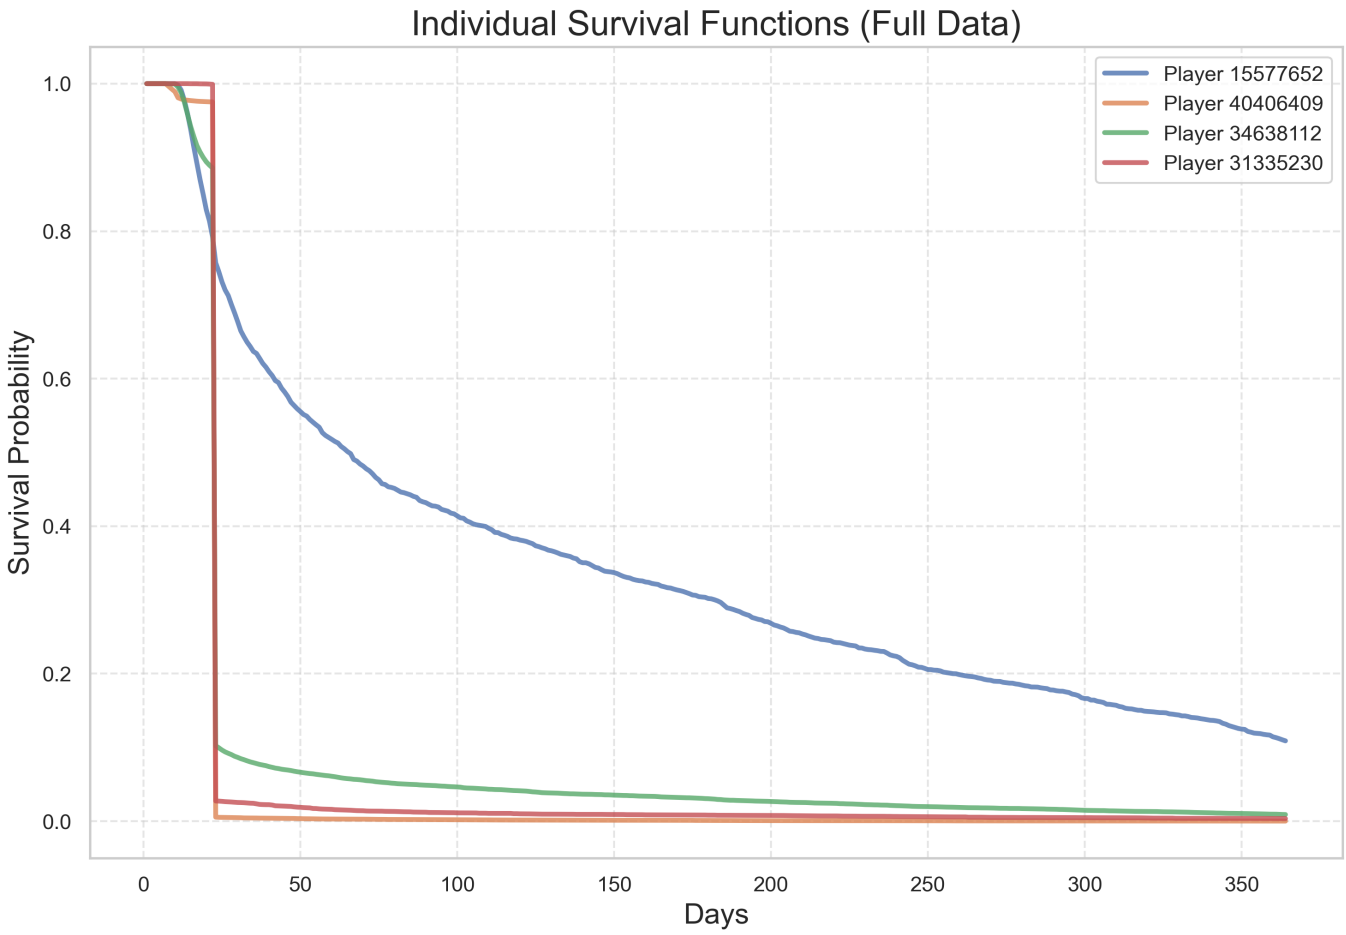
> 业务解读：RSF模型在大部分时间段内预测误差最低，表现优于Cox和K-M模型。

5.3.2 RSF模型Brier分数随时间变化

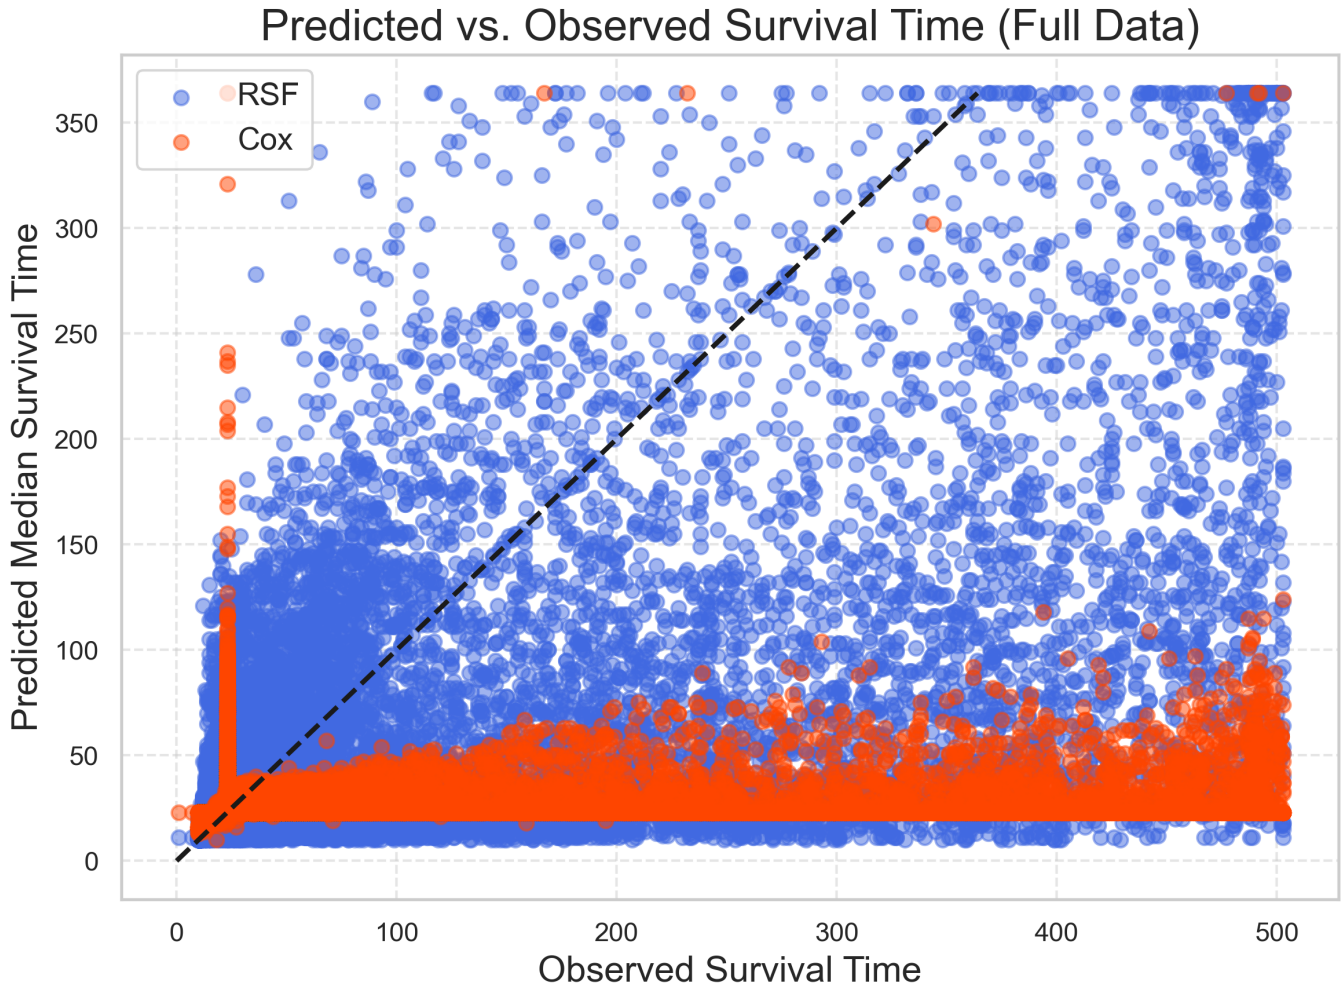


- **RSF模型Brier分数随时间变化**：整体误差低，模型稳定性好。

5.3.3 个体生存预测与一致性



- **个体预测能力**：可为每个玩家生成个性化生存函数，中位生存时间预测误差±7.9天。



- **预测-观测一致性**：散点分布接近对角线，模型预测能力强。

5.4 模型适用性对比与集成策略

5.4.1 各模型适用性对比

模型	优势	局限	适用场景
Kaplan-Meier	简单直观、无分布假设	不能多变量分析	整体趋势、分组对比
Cox模型	可解释性强、处理删失	需比例风险假设	风险因素识别、相对风险量化
RSF	预测精度高、处理高维	计算复杂、可解释性较弱	个体预测、复杂关系

5.4.2 模型集成策略

- 使用Cox模型识别关键风险因素
- 使用RSF模型进行个体化精准预测
- 使用K-M曲线进行整体趋势和分组验证

---

6. 业务洞察与建议

6.1 用户流失模式

- **早期流失严重：**30天内流失率31.5%，60天内流失率48.8%
- **付费用户粘性更强**：高付费用户30天生存概率比低付费用户高24.6个百分点
- **活跃度是关键**：高活跃用户60天生存概率比低付费用户高16.6个百分点

6.2 关键风险因素

1. **活跃率（activity_ratio）**：最重要的预测因子，活跃率每增加10%，流失风险降低约70%
2. **充值金额（total_money）**：付费行为与用户粘性高度正相关
3. **在线时长（onlineTime_mean）**：游戏投入度的重要指标
4. **最后登录时间（days_since_last_login）**：用户行为变化的敏感指标
5. **VIP等级（vip_level）**：用户价值的重要体现

6.3 用户群体差异

- **鲸鱼用户（Top 5%）**：生存概率最高，需要重点保护
- **付费用户**：生存概率中等，有提升空间
- **免费用户**：流失风险最高，需要激活策略

6.4 用户挽留策略

1. **精准干预**：基于模型预测，对高风险用户提前干预。例如，针对预测30天内流失概率高于80%的用户，推送专属礼包或回流活动。
2. **分层运营**：针对不同风险群体制定差异化策略。高风险用户重点召回，中风险用户加强活跃激励，低风险用户提升付费转化。
3. **活跃度提升**：通过限时活动、签到奖励等方式提高用户活跃率，延长生命周期。
4. **付费引导**：合理引导免费用户转化为付费用户，如首充礼包、分层付费激励。

6.5 产品优化建议

1. **新手引导**：优化前30天的新用户体验，提升新手留存。
2. **社交功能**：增强用户间的社交连接，提升用户粘性和归属感。
3. **内容更新**：保持游戏内容的新鲜度，定期推出新玩法和活动。
4. **奖励机制**：设计合理的奖励体系，激励用户持续活跃和付费。

6.6 业务落地案例

- **精准营销**：基于模型预测结果，自动筛选高风险用户，定向推送召回短信、App推送或专属礼包，提升召回率。
- **用户生命周期管理**：结合个体生存曲线，动态调整用户分层和运营策略，实现自动化生命周期管理。
- **产品迭代**：根据模型识别的关键风险因子，优化游戏机制和活动设计，提升整体留存和付费。

6.7 模型价值与技术贡献

- **预测能力**：不仅预测是否流失，还能预测何时流失，支持个体化运营。
- **可解释性**：明确识别影响用户生存的关键因素，为运营决策提供数据支持。
- **自动化与可扩展性**：模型可集成到业务系统中实现自动化预测，适用于其他游戏或产品。
- **方法创新**：将生存分析与集成学习方法结合，提升了预测精度和业务指导价值。

---

7. 总结与展望

本文基于全量数据，系统应用生存分析方法对游戏用户流失进行了建模与预测。实验表明，RSF模型在预测准确性和变量解释性方面均优于传统方法。未来可进一步挖掘社交行为等更丰富的特征，提升模型对长期留存用户的预测能力。

本研究实现了从原始数据到生存分析全流程的自动化建模与可视化，输出了可解释的风险因素和群体差异分析结果，为游戏精细化运营提供了坚实的数据基础。
